Offline RL no CartPole: antes e agora

Resumo dos testes em 1 página · 06/11/2026. Retorno no CartPole-v1 (máximo 500), 50 episódios por modelo. “Slides” é o que as apresentações mostram hoje; “agora” é média ± desvio de 5 seeds (0 a 4) aos 15.000 passos, salvo indicação.

A mesma medida, antes e agora

Medida	Slides	Agora	Situação
IQL no ruim (τ = 0,7)	187	221 ± 15	✓ mantém: acima do CQL em toda seed
CQL no medio (α = 0,5)	372	397 ± 62	✓ mantém: dentro da faixa (306 a 478)
CQL no ruim (α = 0,5)	126	121 ± 22	✓ mantém
CQL no misto (α = 0,5)	191	260 ± 133	✗ muda: 123 a 466 entre seeds
BC no misto (regularizado)	140	94 ± 15	✗ muda: o 140 não se reproduz
DQN offline no expert, retorno	9,5	9,4 ± 0,1	✓ mantém: falha em todas as seeds
DQN no expert, viés de Q	+2.737	+231 a +533.830	✗ muda: tamanho de Q varia com a seed
CQL α = 0,1 no expert, viés	−27	−47,11 ± 0,05	✗ muda: régua corrigida (G truncado)
IQL no ruim, τ = 0,5 / 0,7 / 0,9	212 / 187 / 159	209 / 221 / 191	✗ muda: o retorno não cai com τ
BC no misto filtrado	500	500 ± 0 (3 seeds)	✓ mantém
BC no ruim top 10%	72	83 ± 15 (3 seeds)	✗ muda: refeito, dá 83

✓ se mantém ✗ mudou ou precisa ser corrigido no slide

O que se manteve

- ✓ **DQN offline falha no expert** em todas as seeds (retorno de 9,3 a 9,5); qualquer α > 0 no CQL conserta: 500 em todas. (caps. 1 e 7)
- ✓ **Dados expert levam todos a 500.** No ruim, o BC fica abaixo dos próprios dados (8,9 contra 16,0); no medio, faz 500 (dados: 113). (cap. 7)
- ✓ **IQL acima do CQL α = 0,5** no medio, no ruim e no misto, aos 15.000 passos, em todas as seeds. (cap. 7)
- ✓ **IQL no misto: 500** em todas as seeds, com todos os τ e β testados e até 60.000 passos. (caps. 10 e 11)

O que mudou

- ✗ **“Q da ordem de 10^4” no DQN** era uma seed: o viés vai de +231 a +533.830. Fica a falha, não o tamanho de Q. (cap. 7)
- ✗ **“O retorno cai quando τ cresce”:** com 5 seeds é 209 / 221 / 191. O τ = 0,9 só cai com treino longo (101 aos 60.000 passos, uma seed). (cap. 8)
- ✗ **“Só o IQL volta a 500 no misto”:** o CQL α = 0,5 está em 500 aos 3.000 passos nas 5 seeds e cai para 248 aos 15.000. (caps. 7 e 10)
- ✗ **“O IQL é melhor que o CQL, sempre”:** depende de α e do tempo. Com α = 5, o CQL empata no medio e no misto aos 15.000 passos; aos 60.000, cai para 266 no misto e 90 no ruim, contra 500 e 244 do IQL. (caps. 10 e 11)
- ✗ **“Q ≈ 53: o CQL é conservador”:** Q ≈ 53 mede tempo de treino. Uma fórmula sem penalidade acerta Q, e aos 60.000 passos no expert CQL e IQL chegam a 95 (máximo: 100). (caps. 6 e 8)

> **A frase que resiste a tudo:** o IQL mantém o que aprende. O CQL pode alcançá-lo, mas precisa do α certo e da hora certa de parar, e offline não dá para conferir nenhum dos dois.

Em aberto

- Vento (cap. 12): só a heurística foi medida; as políticas treinadas não.
- medio com 60.000 passos: não testado (com α de 5 a 50 está em 500 aos 15.000).
- A causa da queda do CQL não foi isolada (o máximo no alvo é a explicação coerente).
- Uma seed só: τ = 0,9 aos 60.000 passos e o expert aos 60.000 passos.