# Offline RL no CartPole: antes e agora

Resumo dos testes em 3 páginas · 06/11/2026. Retorno no CartPole-v1 (máximo 500), 50 episódios por modelo, 5 seeds (0 a 4) e 15.000 passos, salvo indicação. Detalhes e fontes em Historico/HISTORIA.md.

## O enredo

Começamos corrigindo detalhes da medição e descobrimos que os números andavam sozinhos entre rodadas: parte do que os slides contam era sorte de uma seed. Repetimos tudo com cinco seeds e depois variamos α, β, τ e o tempo de treino. A comparação entre CQL e IQL mudou duas vezes no caminho (caps. 10 e 11).

> **A frase que resiste a tudo:** o IQL mantém o que aprende. O CQL pode alcançá-lo, mas precisa do α certo e da hora certa de parar, e offline não dá para conferir nenhum dos dois.

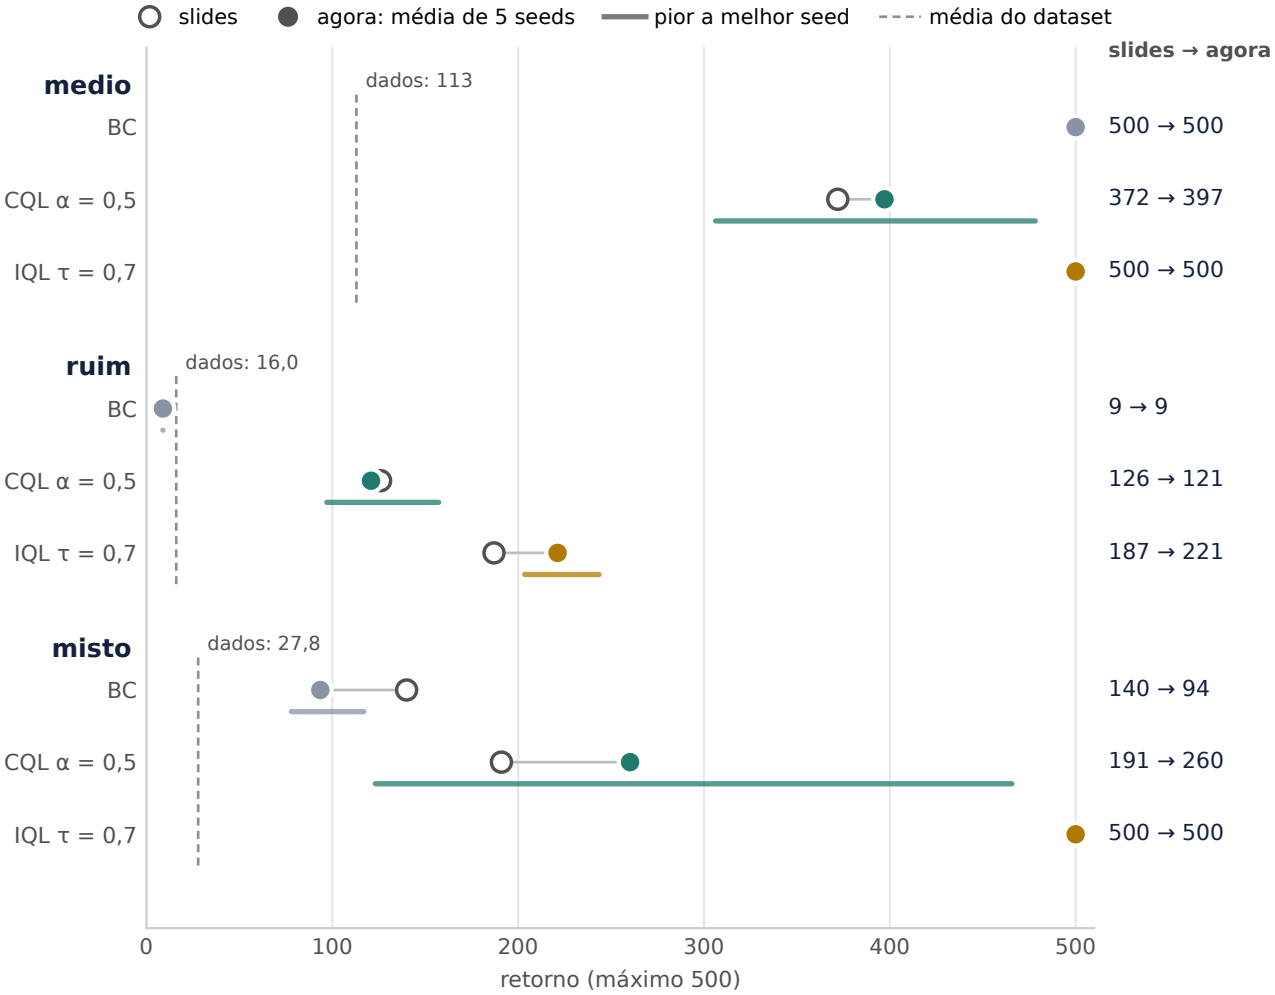
## O resultado principal agora

Média ± desvio entre 5 seeds. BC regularizado (dropout, weight decay, label smoothing), sem parada antecipada.

| Retorno | expert | medio | ruim | misto |
|---|---|---|---|---|
| Média do dataset | 500 | 113 | 16,0 | 27,8 |
| BC regularizado | 500 ± 0 | 500 ± 0 | 8,9 ± 0,0 | 94 ± 15 |
| CQL α = 0,5 | 500 ± 0 | 397 ± 62 | 121 ± 22 | 260 ± 133 |
| IQL τ = 0,7 | 500 ± 0 | 500 ± 0 | 221 ± 15 | 500 ± 0 |

## Slides → agora, por método e dataset

No expert, todos os métodos fazem 500, antes e agora. Ponto vazado: o que os slides mostram. Ponto cheio: média de 5 seeds.




**Como ler:** o IQL subiu no ruim e segue em 500 no medio e no misto; o CQL no misto varia muito entre seeds; o BC no misto ficou abaixo do 140 dos slides, que não se reproduz em nenhuma rodada.

## A mesma medida em cada momento

"1ª rodada": valores citados no PROJECT_GUIDE.md (os arquivos não existem mais). "01/11": commit 6759143. "02/11": correções de medição e BC regularizado (seed 0, 50 episódios). "5 seeds": seeds 0 a 4.

| Medida | Slides | 1ª rodada | 01/11 | 02/11 | 5 seeds |
|---|---|---|---|---|---|
| IQL no ruim, retorno | 187 | 217 | 213 | 204 | 221 ± 15 |
| CQL no medio, retorno | 372 | 430 | 384 | 391 | 397 ± 62 |
| CQL no ruim, retorno | 126 | — | 116 | 116 | 121 ± 22 |
| CQL no misto, retorno | 191 | — | 189 | 187 | 260 ± 133 |
| BC no misto, retorno | 140 | 92 | 124 | 97 | 94 ± 15 |
| BC base no medio 10%, retorno | 385 ± 35 | 356 ± 90 | 399 ± 49 | — | — |
| BC no misto filtrado | 500 | — | — | — | 500 ± 0 (3) |
| BC no ruim top 10% | 72 | — | — | — | 83 ± 15 (3) |
| DQN no expert, retorno | 9,5 | 9,3 | 9,5 | 9,5 | 9,4 ± 0,1 |
| DQN no expert, viés médio de Q | +2.737 | +19.045 | +25.667 | +25.647 | +231 a +533.830 |
| CQL α = 0,1 no expert, viés médio | −27 | −26,7 | −26,7 | −47,1 | −47,11 ± 0,05 |
| DQN no expert, igual aos dados | 50% | 36% | 33% | 33% | 33% (1) / 50% (4) |
| CQL no ruim, igual ao especialista | 73% | 66% | 65% | 65% | 71% ± 7 |
| IQL no ruim, τ = 0,5 / 0,7 / 0,9 | 212 / 187 / 159 | — | 208 / 213 / 214 | 198 / 204 / 207 | 209 / 221 / 191 |

Retorno máximo 500; viés = Q previsto menos o retorno descontado real (máximo possível de Q: 100). (n) = número de seeds. Os dois valores do BC filtrado nos slides vêm da tabela de HISTORIA.md, não dos CSVs.

## O que se manteve

- ✓ **DQN offline falha no expert** em todas as seeds (retorno de 9,3 a 9,5); qualquer α > 0 no CQL conserta: 500 em todas. (caps. 1 e 7)
- ✓ **Dados expert levam todos a 500.** No ruim, o BC fica abaixo dos próprios dados (8,9 contra 16,0); no medio, faz 500 (dados: 113). (cap. 7)
- ✓ **IQL acima do CQL α = 0,5** no medio, no ruim e no misto, aos 15.000 passos, em todas as seeds. (cap. 7)
- ✓ **IQL no misto: 500** em todas as seeds, com todos os τ e β testados e até 60.000 passos. (caps. 10 e 11)

## O que caiu ou mudou

- ✗ **"Q da ordem de $10^4$" no DQN** era uma seed: o viés vai de +231 a +533.830. Fica a falha, não o tamanho de Q. (cap. 7)
- ✗ **"O retorno cai quando τ cresce":** com 5 seeds é 209 / 221 / 191. O τ = 0,9 só cai com treino longo (101 aos 60.000 passos, uma seed). (cap. 8)
- ✗ **"Só o IQL volta a 500 no misto":** o CQL α = 0,5 está em 500 aos 3.000 passos nas 5 seeds e cai para 248 aos 15.000. (caps. 7 e 10)
- ✗ **"O IQL é melhor que o CQL, sempre":** depende de α e do tempo. Com α = 5, o CQL empata no medio e no misto aos 15.000 passos; aos 60.000, cai para 266 no misto e 90 no ruim, contra 500 e 244 do IQL. (caps. 10 e 11)
- ✗ **"Q ≈ 53: o CQL é conservador":** Q ≈ 53 mede tempo de treino. Uma fórmula sem penalidade acerta Q, e aos 60.000 passos no expert CQL e IQL chegam a 95 (máximo: 100). (caps. 6 e 8)

## CQL × IQL depois da sensibilidade (caps. 10 e 11)

Até o cap. 9, o CQL usava α = 0,5 fixo. Depois: α de 0 a 50 e treino até 60.000 passos, 5 seeds, em GPU. Os números de GPU ficam separados da tabela principal (CPU): a maior diferença entre as médias é de 12 pontos.

**O α forte só atrasa a queda.** Retorno, média ± desvio de 5 seeds:

| Método | ruim, 15k | ruim, 60k | misto, 15k | misto, 60k |
|---|---|---|---|---|
| CQL α = 0 (DQN) | 117 ± 21 | 103 ± 20 | 174 ± 87 | 109 ± 4 |
| CQL α = 0,5 | 121 ± 25 | 98 ± 17 | 248 ± 141 | 112 ± 9 |
| CQL α = 2 | 136 ± 11 | 106 ± 5 | 490 ± 17 | 129 ± 33 |
| CQL α = 5 | 192 ± 20 | 90 ± 15 | 500 ± 0 | 266 ± 164 |
| IQL τ = 0,7 | 220 ± 12 | 244 ± 124 | 500 ± 0 | 500 ± 0 |
| BC regularizado | 8,9 ± 0,0 | 8,9 ± 0,0 | 88 ± 14 | 64 ± 11 |

**Acima de α = 5, o CQL vira BC.** Retorno aos 15.000 passos:

| Dataset | α = 5 | α = 10 | α = 20 | α = 50 | BC |
|---|---|---|---|---|---|
| ruim | 192 ± 20 | 175 ± 35 | 17,0 ± 7,6 | 8,9 ± 0,0 | 8,9 ± 0,0 |
| misto | 500 ± 0 | 500 ± 0 | 463 ± 34 | 279 ± 27 | 88 ± 14 |
| medio | 500 ± 0 | 500 ± 0 | 500 ± 0 | 500 ± 0 | 500 ± 0 (CPU) |

## Leitura

- **Aos 15.000 passos, α = 5 empata com o IQL** no medio e no misto (500) e chega perto no ruim (192 contra 220).
- **Aos 60.000, todo α cai.** No misto, α = 5 vai a 266 (108 a 495 entre seeds); no ruim, todos terminam perto de 100. O IQL fica em 500 no misto e 244 no ruim.
- **Penalidade demais copia os dados:** com α = 50 no ruim, o CQL faz 8,9, o mesmo do BC. α vai do Q-learning (α = 0) ao BC (α alto).
- **Escolher α sem jogar não funciona:** o critério do menor viés de Q erra em 2 dos 3 datasets (cap. 11). Offline, nada no treino avisa o α nem a hora de parar.

## Em aberto

- Vento (cap. 12): só a heurística foi medida; as políticas treinadas não.
- medio com 60.000 passos: não testado (com α de 5 a 50 está em 500 aos 15.000).
- A causa da queda do CQL não foi isolada (o máximo no alvo é a explicação coerente).
- Uma seed só: τ = 0,9 aos 60.000 passos e o expert aos 60.000 passos.

## Frases dos slides que precisam mudar

- **IQL, slide 11:** retorno por τ 212 → 187 → 159 (“queda”). Com 5 seeds: 209 / 221 / 191, sem queda contínua.
- **IQL, slide 20:** “o IQL é o único que chega a 500 no misto e o melhor no ruim (187)”. O CQL também chega a 500 no misto, mas cai com o treino; IQL no ruim: 221 ± 15. Trocar a figura pelo quadro de 5 seeds da página 1.
- **CQL, slides 11, 12 e 16:** “Q ≈ 2.700 / 2.450, viés +2.737”. O DQN falha em todas as seeds, mas o viés vai de +231 a +533.830: o tamanho depende da seed.
- **CQL, slides 12 e 16:** “o limite inferior prometido”. No expert, Q ≈ 53 mede tempo de treino (caps. 6 e 8).
- **BC, slide 15:** BC no misto 140 → 94 ± 15 (regularizado); BC filtrado no ruim 72 → 83; IQL no ruim 187 → 221.